

VeriMod

검증 가능한 AI 콘텐츠 모더레이션 감사 프로토콜

AI가 게시물을 삭제·차단한 판정과 그 근거를 블록체인에 봉인해, 플랫폼조차 사후에 바꿀 수 없게 만들고 누구나 조작 여부를 직접 재검증하게 하는 프로토콜.

01 개요

AI 검열에 대한 검증 가능한 영수증.
판정과 근거를 온체인에 봉인하고, 이용자가 직접 무결성을 확인한다.

봉인

AI 판정 레코드를 해시로 만들어 스마트 컨트랙트에 앵커링

재검증

누구나 레코드를 재해싱해 온체인 해시와 대조, 변조를 즉시 적발

트랙 부합

AI가 판단하고 블록체인이 그 판단의 불변성을 증명하는 융합 구조

02 문제 정의 및 배경

하루 수백만 건의 게시물이 AI로 자동 삭제·차단되지만, 그 판정은 완전한 블랙박스다.

사회적 배경	기술적 원인	규제 압력
이용자는 왜 지워졌는지, 그 근거가 사실인지, 나 중에 플랫폼이 근거를 바꾸지 않았는지 확인할 방법이 없다. 방어권과 알 권리가 비어 있다.	모든 판정 기록이 플랫폼 내부 중앙 DB에 저장되 고, 플랫폼이 언제든 수정·삭제할 수 있으며, 이를 검증할 제3자가 없다. 투명성 리포트는 결국 자 기신고다.	EU DSA는 모더레이션 결정의 기록·투명성 의무 를, EU AI Act는 고위험 자동결정의 추적·로깅 의무를 부과한다. 한국 AI 기본법도 2026년 1월 시행됐다.

수요는 이미 **법으로 확정**됐지만, 이를 실제로 구현한 서비스는 아직 시장에 거의 없다.

03 기존 서비스는 어디까지 왔나

이미 여러 방식이 존재한다. 그러나 모두 기록을 감사받는 당사자가 통제한다는 같은 한계에 묶여 있다.

플랫폼 자체 알림 · 이의제기

대형 SNS·동영상 플랫폼의 커뮤니티 가이드라인 위반 통보

"커뮤니티 규정 위반" 수준의 한 줄 사유만 제공된다. 어떤 항목에서 몇 점이 나왔는지, 어떤 모델이 판단했는지 알 수 없고 통보 내용이 사후에 바뀌어도 이용자는 확인할 수단이 없다.

투명성 리포트

반기·분기 단위 삭제 건수 집계 공개

집계된 총량만 공개될 뿐 개별 건의 판정 근거는 담기지 않는다. 수치 자체를 플랫폼이 산출하므로 결국 자기신고이며, 제3자가 원장을 대조해 검증할 수 없다.

상용 모더레이션 API

외부 AI 모더레이션 엔드포인트를 호출하는 방식

항목별 점수까지는 돌려주지만, 그 응답을 보관·표시하는 책임은 전적으로 도입 플랫폼에 있다. 저장 단계에서 값을 바뀌도 API 제공자도 이용자도 알아챌 방법이 없다.

외부 심의기구 · 감사 로그

독립 심의위원회, 내부 감사 로그 보존

심의 대상은 극히 일부 사건에 한정되고 결론까지 수개월이 걸린다. 감사 로그는 플랫폼 서버에 남아 있어, 권한을 가진 내부자가 수정하면 흔적이 남지 않는다.

네 방식 모두 "플랫폼을 믿어라"를 전제한다. VeriMod는 믿지 않아도 확인 가능하게 만든다.

03 차별성 및 기대효과

비교 축	플랫폼 자체 정보	투명성 리포트	모더레이션 API	VeriMod
기록 위치	플랫폼 중앙 DB	집계 문서(PDF)	도입사 DB	해시 온체인 봉인
공개 단위	한 줄 사유	기간별 총량	항목 점수(내부)	개별 건 전체 근거
검증 주체	플랫폼 독점	플랫폼 자기신고	도입 기업	이용자 포함 누구나
사후 변조	적발 불가	적발 불가	적발 불가	해시 불일치로 즉시 적발
확인 소요	문의 후 수일	분기 단위	해당 없음	클릭 즉시

플랫폼	이용자	규제기관 · 시민단체
DSA·AI 기본법이 요구하는 기록 의무를 자동 증빙으로 전환해, 감사 대응에 드는 인력·시간 비용을 줄인다.	오타으로 차단됐을 때 항목별 점수와 근거가 담긴 영수증을 확보하고, 이의제기 이력이 삭제되지 않는다.	플랫폼의 협조 없이도 공개 원장에서 판정 무결성을 직접 표본 감사할 수 있다.

04 서비스·솔루션 개요

STEP 1 · 판정

AI 모더레이션

욕설·혐오·폭력·성적·스팸·허위정보
항목별 점수와 승인/보류/차단
판정

STEP 2 · 복인

온체인 앵커링

원문 해시·결과·점수·근거·모델 버전·시각을 묶어 SHA-256 해시만
컨트랙트에 기록

STEP 3 · 검증

재해싱 대조

보관된 레코드를 다시 해싱해 온체인
해시와 비교 — 일치는 무결, 불
일치는 변조

STEP 4 · 이의

추가 전용 원장

이의제기 사실과 처리 이력이
append-only로 남아 삭제되지
않음

도입 주체 — 플랫폼

규제 대응 비용을 줄이는 컴플라이언스 자동 중빙

어차피 남겨야 하는 감사 로그를 "우리는 조작하지 않았다"는 증명으로
바꾼다. 소송·이의제기 상황에서 판정 근거를 위변조 불가로 제시할 수
있다.

검증 주체 — 이용자

검열 영수증과 버튼 하나의 재검증

언제, 어떤 시가, 어떤 항목에서 몇 점으로 차단했는지 받아보고 직접 확
인한다. 플랫폼이 말을 바꾸면 해시 불일치로 즉시 적발된다.

05 핵심기술 스택

판단 계층 AI	게시물 → 항목별 점수 + 승인/보류/차단 판정 + XAI 근거 생성	LLM 기반 분류 · XAI
보인 계층 블록체인	판정 레코드 해시를 스마트컨트랙트에 앵커링, 등록·조회·이의 기록	Solidity · EVM 테스트넷(Base Sepolia)
저장 계층	원문과 상세 근거는 오프체인에 두고 온체인에는 지문만 남김	IPFS 등 탈중앙 스토리지
검증 계층	클라이언트 재해싱 → 컨트랙트 조회 → 무결/변조 판정	React · Web Crypto(SHA-256) · ethers.js

원문은 온체인에 올리지 않는다 — 프라이버시를 지키면서 저장 비용을 낮추고, 탈중앙 스토리지 요건을 동시에 충족한다.

06 프로젝트 구현 계획 ① — 적용 및 융합 방안

블록체인 기술 적용 방안

판정 레코드를 직렬화해 SHA-256 해시를 생성하고, 해시만 스마트컨트랙트에 등록한다.

컨트랙트 인터페이스는 판정 해시 등록, 판정 조회, 이의 기록 세 가지로 최소화한다.

이의제기는 덮어쓰기 없이 추가만 가능한(append-only) 구조로 이력을 보존한다.

EVM 계열 테스트넷에 배포해 가스 비용과 처리량을 실측한다.

블록체인 + AI 융합 방안

AI는 "판단"을, 블록체인은 "그 판단이 변하지 않았음의 증명"을 맡는다.

AI만 있으면 판정은 나오지만 아무도 검증할 수 없고, 블록체인만 있으면 무엇을 기록할지 판단할 지능이 없다.

XAI 근거를 판정 레코드에 포함해 봉인하므로, 근거 한 글자만 바뀌어도 해시가 달라진다.

두 기술이 결합해야 "검증 가능한 자동 판정"이 완성된다 — 트랙 1에 정확히 부합하는 지점.

최종 구현 목표 — 판정 · 봉인 · 검증 · 변조 적발이 실제로 작동하는 엔드투엔드 프로토타입.

06 프로젝트 구현 계획 ② — 개발 일정

~ 9/19 사전 OT

기획 · 데모

주제 확정, 판정 → 봉인 → 검증이 실제로 도는 프로토타입 데모 완성

9월 말 ~ 10월 말 (7주)

본개발 · 멘토링

컨트랙트 테스트넷 배포, 판정 정확도 개선, 검증 UI 고도화

11/6 ~ 11/7

본선

전 계층 통합, 시나리오 리허설, 최종 발표 및 시연

주차별 세부 계획

주차	블록체인 · 백엔드	AI · 프론트엔드	멘토링에서 확인할 것
1-2주	컨트랙트 인터페이스 설계, 레코드 직렬화 규칙 확정	모더레이션 항목 체계 정의, 판정 프로그램 1차 구현	해시 앵커링 구조가 감사 요건을 충족하는지
3-4주	테스트넷 배포, 가스비·처리량 실측, 이의 기록 함수 구현	XAI 근거 생성, 오탐 사례 수집과 임계값 조정	근거 테스트의 설명가능성·재현성 확보 방법
5-6주	오프체인 스토리지 연동, 변조 시나리오 테스트	클라이언트 재해싱 검증 화면, 이용자용 영수증 화면	프라이버시와 검증 가능성의 균형점
7주 ~ 본선	통합 테스트, 배포 주소·트랜잭션 정리	시연 시나리오 구성, 발표 자료 정리	심사 관점에서 보완할 지점

* 멘토는 배정 후 확정하며, 위 표의 "확인할 것"을 회차별 질의 항목으로 준비한다.

07 팀 구성 및 역할 분담

2인 팀으로, 네 계층을 "판단하는 쪽"과 "증명하는 쪽"으로 나눈다. 판정 레코드 규격만 초기에 합의하면 두 축은 독립적으로 병렬 개발이 가능하다.

팀원 A · 팀장 — AI / 프론트엔드

이름 기재

- LLM 기반 모더레이션 판정과 항목별 스코어링
- XAI 근거 생성, 오탐 사례 기반 임계값 조정
- React 검증 웹앱, 사용자용 검열 영수증 화면
- 문제 정의·규제 리서치, 제안서 및 발표 총괄

주요 기술스택 · GitHub ID · 수행 경험 기재

팀원 B — 블록체인 / 백엔드

이름 기재

- Solidity 컨트랙트 설계와 테스트넷 배포
- 판정 레코드 직렬화·해시 앵커링, 이의 기록 함수
- 오프체인 스토리지 연동, 변조 시나리오 테스트
- 저장소 관리, 배포 주소·트랜잭션 증빙 정리

주요 기술스택 · GitHub ID · 수행 경험 기재

공동 작업 — 판정 레코드 스키마 합의, 통합 테스트, 시연 시나리오 리허설. 코드 리뷰는 Pull Request 기반으로 상호 진행한다.

08 개발증빙 ① — 데모 시연 시나리오

데모 시연 순서 — 목업이 아닌 실제 작동

- 01 게시물을 입력하면 시가 항목별 점수로 판정한다.
- 02 판정을 온체인에 봉인하면 원장에 블록이 쌓이고 트랜잭션·봉인 해시가 생성된다.
- 03 무결성 검증을 돌려 재계산 해시가 봉인 해시와 일치함을 확인한다.
- 04 플랫폼이 판정 근거를 몰래 조작한 뒤 재검증하면, 해시 불일치로 조작이 즉시 적발된다. 단일 DB였다면 흔적 없이 통과했을 조작이다.
- 05 이용자 시점 화면 — 오탐으로 차단된 이용자가 검열 영수증을 받고 스스로 조작을 잡아낸다.

4번 장면이 이 프로젝트의 승부처다 — 기존 방식이라면 흔적 없이 지나갔을 조작이, 화면 위에서 즉시 드러난다.

08 개발증빙 — GitHub 저장소

모든 개발 산출물과 과정을 단일 GitHub 저장소에 공개한다. 커밋 이력 자체가 개발 과정의 증빙이 되며, 심사위원이 언제든지 진행 상황을 직접 확인할 수 있다.

저장소 구조

contracts · ai · web · docs 네 디렉터리로 계층별 코드를 분리하고, README에 아키텍처와 실행 방법을 정리한다.

이슈 · 마일스톤

주차별 계획을 이슈로 등록하고 마일스톤에 묶어, 일정 대비 실제 진행률을 저장소에서 그대로 확인할 수 있게 한다.

커밋 · 브랜치 전략

기능 단위 브랜치에서 작업하고 Pull Request로 병합한다. 2인 상호 리뷰를 거쳐 main에 반영해 진행 이력을 남긴다.

배포 · 실행 증빙

테스트넷 컨트랙트 주소와 트랜잭션 해시, 봉인된 판정 레코드 예시, 시연 영상 링크를 docs에 함께 기록한다.

저장소 주소

github.com/____/verimod — 팀 확정 후 기재

레퍼런스

EU DSA · EU AI Act · 한국 AI 기본법(2026.1 시행), 고위험 AI 자동결정의 온체인 감사 관련 선행 연구

09 기타 사항 — 확장 비전

콘텐츠 모더레이션은 시작점이다. "AI가 판단하고 블록체인이 무결성을 증명한다"는 구조는 **다른 고위험 AI 자동결정으로** 그대로 확장된다.

콘텐츠 모더레이션 현재 범위	대출 심사 확장	채용 평가 확장	의료 진단 확장
--------------------	-------------	-------------	-------------

"그냥 로그 DB 쓰면 되지 않나?" 검열당한 이용자가 검열한 플랫폼의 DB를 믿을 이유가 없다. 기록은 감사받는 당사자가 통제해선 안 된다.	"플랫폼이 왜 자기 감시 도구를?" 규제가 어차피 감사 로그를 강제한다. 대응을 자동화 해 비용을 줄이고 분쟁 시 법적 방어에 유리하다.	"프라이버시 문제는?" 원문은 온체인에 올리지 않고 해시만 앵커링한다. 원본은 오프체인 탈중앙 스토리지에 둔다.
--	---	---

VeriMod — 검증 가능한 AI 결정 인프라로.